

软件过程改进方案设计文档

1. 设计目标与改进范围

本方案面向 SpecAlign 已有的软件过程定义进行改进设计。第一次过程定义文档已经依据 ISO/IEC/IEEE 12207:2017 对项目进行了裁剪，形成 16 个软件过程，并指出项目具有小团队、数据产品、流水线式生命周期和外部 LLM API 依赖等特点。本次改进不重新定义一个完全不同的过程体系，而是在原有过程框架中嵌入 AI 参与节点，使需求、设计、构建、测试、质量保证、运维和维护改进等关键过程具备更强的智能化能力。

本方案的总体目标是建立一套可落地、可度量、可审计的人机协同过程。所谓可落地，是指每个 AI 参与节点都必须有明确输入、输出和责任角色，不能只停留在“使用 AI 提高效率”的笼统描述。所谓可度量，是指 AI 引入后需要通过时间、覆盖率、采纳率、缺陷发现率和数据污染率等指标判断效果。所谓可审计，是指所有 AI 输出都需要记录提示词、模型版本、输入材料和人工复核结论，避免 AI 结果游离在正式过程之外。

2. 改进原则

本方案遵循四项原则。第一，AI 输出定位为候选工作产品，而不是最终基线。AI 可以生成规则解释、测试场景、数据质量意见和运维异常摘要，但规则基线、测试规格、数据放行和过程变更仍必须由人工确认。第二，AI 活动必须嵌入现有过程，不单独形成无法管理的“聊天式工作流”。凡是用于正式交付的 AI 输出，都应当进入配置管理和质量保证范围。第三，AI 工具使用必须具备可替换性，避免过程依赖某一个具体模型或平台。第四，风险控制应当与效率提升同时设计，不能在提高生成速度的同时降低数据可靠性。


为便于后续评估，本方案将 AI 贡献度定义为：


$$Contribution_{AI} = \frac{N_{AI_accepted}}{N_{final}}$$

其中， $N_{AI_accepted}$ 表示最终交付物中来自 AI 候选且通过人工复核的有效项数量， N_{final} 表示最终交付物中的有效项总数。该指标只反映 AI 参与程度，不直接等同于质量水平，因此必须与人工复核通过率、缺陷率和数据污染率共同使用。

3. 改进后的总体流程

改进后的 SpecAlign 仍保持原有流水线特征，但在关键节点增加 AI 协作活动。整体流程从行为规范和 API 配置获取开始，经由 AI 辅助规则审查、测试规格设计、候选测试用例生成、多智能体对抗测试、AI 辅助数据质量复核和 DPO 数据交付，最终进入模型训练反馈与过程改进。其核心思想是：AI 在上游帮助理解规则，在中游帮助扩展测试场景，在下游帮助识别数据质量和运行异常，并把反馈重新带回需求与设计阶段。





该流程没有改变 SpecAlign 的核心架构。规划器、攻击者、防御者、安全评审和质量评审仍然构成对抗测试主体。AI 改进主要发生在过程管理层：它增强规则解释、测试设计、样本构建、质量复核和反馈分析，而不是取代原系统的执行逻辑。

4. 新增角色与职责

为了使 AI 活动能够纳入正式过程，本方案新增四类角色。AI 过程协同工程师负责维护提示词模板、模型参数、输入输出格式和调用记录，保证 AI 使用不是临时性的个人操作。AI 测试分析师负责审查 AI 生成的测试场景和测试用例，判断其是否真正对应目标规则、是否具有足够策略多样性、是否适合进入正式测试。AI 数据质量审查员负责检查 DPO 样本中的偏好对有效性、安全证据完整性和数据污染风险。AI 运维分析员负责对脱敏后的日志和运行指标进行摘要与归因，但不直接执行任何配置修改。

原有角色的职责也需要相应调整。项目负责人负责批准 AI 参与范围和最终过程变更，质量保证人员负责检查 AI 输出是否经过复核，开发工程师负责将 AI 参与节点接入现有流水线，运维人员负责日志脱敏、异常处理和恢复验证。模型训练团队则需要在 DPO 数据使用后反馈训练效果，使维护改进过程能够形成闭环。

5. 关键过程改进设计

5.1 PRC-REQ：需求分析过程改进

原需求分析过程以行为规范文档为输入，经过规则解析、方向标注、场景标注和语义族聚类形成结构化规则。改进后，在规则解析之后增加 AI 规则语义审查活动。AI 对每条规则输出规则意图、适用场景、例外条件、潜在冲突和原文依据，并将不确定内容标记为“待人工确认”。人工复核通过后，规则解释才能进入规则基线。

该过程的质量标准包括：高风险规则必须包含原文依据；AI 解释中无原文依据的新增内容不得进入基线；人工复核通过率应作为过程度量指标；被修改或删除的 AI 解释必须记录原因。通过这一改进，需求分析过程从单纯的规则抽取扩展为规则理解与规则审查，有利于减少后续测试设计中的语义偏差。

5.2 PRC-DES：设计过程改进

原设计过程重点在于规则采样和优先级排序。改进后，AI 根据规则基线生成风险场景和测试策略建议，并辅助形成测试规格覆盖审查表。设计审查不再只检查是否覆盖了足够数量的规则，还要检查是否覆盖高风险规则、是否包含多种攻击策略、是否存在重复场景和低价值场景。

建议采用设计覆盖评分：

$$Score_{design} = 0.35C_{rule} + 0.25C_{risk} + 0.25D_{strategy} + 0.15Q_{review}$$

其中， C_{rule} 表示规则覆盖率， C_{risk} 表示高风险规则覆盖率， $D_{strategy}$ 表示策略多样性， Q_{review} 表示人工审查通过比例。该评分用于辅助设计审查，低于阈值的测试规格需要重新生成或人工补充。

5.3 PRC-CON：构建过程改进

构建过程的改进重点是 AI 辅助测试用例生成。AI 根据目标规则和策略类型生成候选测试提示，并为每条候选标注目标规则、攻击意图、预期风险、用户语气和复核要点。随后，系统进行结构校验，检查字段是否完整；测试分析师进行语义复核，检查候选是否真正触发目标规则；质量保证人员抽检最终保留样本。

该过程的输出不只是测试提示文本，而是结构化测试用例。每条有效用例应至少包含 *RuleID*、*StrategyType*、*Prompt*、*ExpectedRisk*、*ReviewPoint* 五个字段。这样可以保证测试用例既可执行，也可追溯。

5.4 PRC-QA：质量保证过程改进

质量保证过程需要检查 AI 活动是否按照定义执行。改进后的 QA 不仅检查最终 DPO 数据集，还检查 AI 输出链路本身，包括提示词是否使用正式模板、输入是否脱敏、输出是否记录、人工复核是否完成、被拒绝的 AI 样本是否记录原因。对于 DPO 样本，AI 可以作为二级复核工具标记潜在污染，但最终放行仍由质量保证人员确认。

数据质量复核可以使用如下合格率指标：

$$PassRate_{DPO} = \frac{N_{valid_pairs}}{N_{checked_pairs}}$$

其中， N_{valid_pairs} 表示通过复核的偏好对数量， $N_{checked_pairs}$ 表示被检查的偏好对总数。若该指标低于设定阈值，则需要回到测试用例构建或评审提示词设计阶段进行修正。

5.5 PRC-OPE：运维过程改进

SpecAlign 的运行依赖 LLM API，异常来源复杂。改进后的运维过程增加 AI 日志摘要与异常归因活动。AI 对脱敏后的日志片段进行分析，输出异常类型、影响范围、证据片段、可能原因和建议动作。常见异常类型包括认证失败、速率限制、网络超时、模型拒答、输出格式错误、上下文长度超限和评审结果缺失。

该过程必须坚持只读原则。AI 可以建议检查密钥、降低并发、切换模型或重新运行某个阶段，但不能自动修改配置，也不能直接执行恢复动作。运维人员处理完成后，需要记录恢复验证结果，并将高频异常反馈给基础设施管理和风险管理过程。

5.6 PRC-MAI：维护与改进过程改进

维护改进过程是原过程中的主要短板。改进后，DPO 数据交付不再作为流程终点，而是要求模型训练团队反馈使用结果，包括训练后模型违规率、帮助性评分变化、失败规则分布和策略成功率变化。AI 根据这些反馈生成过程改进建议，例如调整高风险规则采样权重、补充某类攻击策略、修改评审提示词或优化 Context Pool 检索策略。

该过程的关键在于形成闭环。若某类规则在多个版本中持续高违规率，则应回到需求分析过程检查规则表达是否清晰，回到设计过程提高该类规则优先级，回到构建过程补充更多测试样本。只有当反馈能够改变上游过程，维护改进才不只是结果总结。

6. 工具链选型与集成方式

改进环节	推荐工具	核心功能	集成方式	预期效果
规则语义审查	OpenAI GPT-5 / Codex	长文本理解、规则解释、冲突识别	读取规则清单后生成审查表	降低人工初审耗时，提高冲突发现率
测试规格设计	OpenAI API / Copilot Chat	风险场景扩展、策略覆盖建议	在采样结果后生成设计审查输入	提高高风险规则覆盖与策略多样性
测试用例生成	Codex / OpenAI API	多策略候选提示生成	生成结构化测试用例 JSON	提高候选样本数量和初稿效率
数据质量复核	LLM Judge + 规则脚本	偏好对审查、证据检查	DPO 导出前进行二级复核	降低数据污染风险
运维异常分析	LLM 日志摘要工具	错误归类、原因解释	对脱敏日志进行只读分析	缩短异常定位时间
维护改进建议	LLM 分析助手	趋势解释、改进建议	分析统计报告和训练反馈	建立持续改进闭环

7. 风险评估与应对策略

风险类型	具体表现	过程影响	应对策略
AI 幻觉	生成规范中不存在的规则解释	需求基线被污染	要求原文引用，人工确认后入库
模型偏见	对某些风险场景过度或不足判断	测试样本分布失衡	多策略覆盖检查，人工抽样复核
数据泄露	将 API 密钥或敏感日志输入 AI	安全事故	日志脱敏，密钥过滤，只读分析
技术依赖	过程过度依赖单一模型	工具失效时流程中断	保留人工路径，支持多模型替换
输出不可复现	同一提示多次结果差异较大	审计困难	固定模板、记录模型参数、保存输出
责任边界模糊	AI 建议与人工决策混淆	放行责任不清	明确 AI 只生成候选，人工负责确认

8. 交付物与质量门

改进后新增或更新的交付物包括《规则语义审查表》《AI 风险场景扩展表》《测试规格覆盖审查表》《AI 生成测试用例清单》《AI 数据质量复核报告》《AI 运维异常分析记录》《训练效果反馈表》和《过程改进建议记录》。这些交付物应采用 Markdown、JSON 或 JSONL 格式保存，并纳入 Git 管理。

为保证过程质量，应设置四道质量门。第一道质量门位于需求分析结束处，规则解释必须通过人工复核后才能进入设计阶段。第二道质量门位于测试规格设计结束处，高风险规则覆盖率和策略多样性必须达到阈值。第三道质量门位于测试用例构建结束处，候选样本必须通过结构校验和语义抽检。第四道质量门位于 DPO 数据交付前，数据质量复核发现的污染样本必须隔离。

9. 总结

本方案在 SpecAlign 原有 16 个过程基础上进行 AI 化改进，重点不是增加形式化的 AI 名称，而是把 AI 活动嵌入实际过程节点。通过规则语义审查、风险场景扩展、测试用例候选生成、数据质量复核、运维异常分析和维护改进建议，SpecAlign 可以在保持原有可控结构的同时提高效率和质量。该方案强调 AI 输出可追溯、人工复核不可省略、质量指标可量化，因此具有较强的落地性。