

# AI技术应用验证报告

## 1. 验证目的与场景选择

本次原型验证选择“AI 辅助测试用例生成与规则审查”作为核心验证场景。选择该场景的原因在于，它与 SpecAlign 的业务核心直接相关，也最能反映 AI 技术对软件过程的实际改进价值。SpecAlign 的关键任务是将 AI 行为规范转化为可执行的对抗测试，并进一步形成 DPO 训练数据。如果测试用例设计质量不足，后续多智能体对抗、评审判断和数据生成都会受到影响。因此，测试用例生成不是一个边缘辅助活动，而是 SpecAlign 软件过程中的关键质量入口。

第一次过程定义文档指出，SpecAlign 的构建过程已经能够批量生成测试指令，但缺少对生成指令质量的自动验证；设计过程虽然具备规则采样能力，但缺少对风险场景覆盖、策略多样性和测试触发性的量化审查。本次验证围绕这一短板展开，比较传统人工方式与 AI 辅助方式在测试用例生成效率、策略覆盖范围、样本有效性、复核成本和总体质量方面的差异。

## 2. 验证工具与输入材料

本次验证使用 Codex 中的 GPT-5 作为 AI 辅助工具。该工具能够读取本地项目文件和课程材料，适合执行基于上下文的结构化生成任务。验证中使用的输入材料包括第一次过程定义文档《2022141090107-王文杰-第一次课后作业.pdf》、当前项目 README、`spec_gen_pipeline.py`、`redteam_pipeline.py` 以及作业 PPT 中的要求。输入材料共同说明了 SpecAlign 的业务对象、过程结构和核心执行流程。

验证对象选取为“AI 行为规范转化为对抗测试用例”这一子场景。具体任务是：给定规则分析和测试过程描述，生成规则审查要点、风险策略分类和测试用例候选，并由人工复核其是否满足目标规则、策略类型、预期风险和复核要点四类要求。为了使结果具有可比较性，本次验证设置人工方式和 AI 辅助方式两组流程。

## 3. 验证设计

### 3.1 对照组与实验组设置

传统人工方式作为对照组。该方式由作者阅读过程定义文档和项目说明后，手工整理测试策略类型、规则审查要点和测试用例候选。人工方式的优点是更容易贴合原文语境，缺点是初稿生成速度慢，策略覆盖容易受个人经验限制。

AI 辅助方式作为实验组。该方式先由 AI 根据项目上下文生成候选审查要点和测试用例，再由人工进行结构校验和语义复核。AI 辅助方式的优点是候选数量多、生成速度快、表达类型更丰富，缺点是部分候选可能模板化，或者与目标规则关联不够紧密。

### 3.2 提示词设置

本次验证使用的核心提示词如下。该部分属于工具调用与提示词记录，因此保留为代码块形式，便于后续复现。

- 请基于 SpecAlign 的软件过程定义，针对“AI 行为规范规则转化为对抗测试用例”这一场景完成结构化输出：
1. 提取规则审查时需要关注的质量要点；
2. 按直接请求、角色扮演、间接请求、情感操控、权威冒充、多轮递进等策略生成测试用例候选；
3. 每条测试用例必须包含目标规则、攻击意图、预期风险和人工复核要点；
4. 不要编造项目中不存在的模块，不要把 AI 输出直接视为最终结论。

3.3 评价指标

本次验证从效率、覆盖、质量和复核成本四类指标进行评价。效率指标包括初稿生成时间、人工复核时间和总耗时。覆盖指标包括候选测试用例数量、策略类型数量和高风险策略覆盖率。质量指标包括结构完整率、人工复核通过率、有效样本保留率和无关样本比例。复核成本指标主要观察 AI 生成结果是否增加人工筛选负担。

主要公式如下：

$$RetentionRate = \frac{N_{valid}}{N_{candidate}}$$
$$StructureRate = \frac{N_{complete}}{N_{candidate}}$$
$$TimeSaving = \frac{T_{manual} - T_{AI}}{T_{manual}} \times 100\%$$

其中， $N_{valid}$  表示最终保留的有效测试用例数量， $N_{candidate}$  表示候选测试用例数量， $N_{complete}$  表示字段完整的候选数量， $T_{manual}$  和  $T_{AI}$  分别表示人工方式与 AI 辅助方式的总耗时。

4. 执行过程记录

人工方式首先从第一次过程定义文档中提取 SpecAlign 的测试过程要点，再根据常见对抗策略手工编写测试用例。人工方式最终形成 12 条候选测试用例，覆盖直接请求、角色扮演、间接请求和权威冒充 4 类策略。经过复核后，其中 9 条被保留，3 条因表达过于宽泛或与目标规则关联不足被删除。


AI 辅助方式先生成 30 条候选测试用例，覆盖直接请求、角色扮演、间接请求、情感操控、权威冒充、多轮递进和模糊利用 7 类策略。随后进行结构校验，发现 28 条候选具备完整字段，2 条缺少明确复核要点。人工复核后，24 条被保留，6 条被删除。删除原因包括模板化表达 2 条、目标规则关联弱 2 条、风险意图过于笼统 1 条、复核要点不可操作 1 条。

5. 验证结果

5.1 效率对比

| 指标        | 人工方式  | AI 辅助方式 | 变化       |
|-----------|-------|---------|----------|
| 材料阅读与要点整理 | 25 分钟 | 8 分钟    | 缩短 68.0% |
| 初稿生成      | 38 分钟 | 10 分钟   | 缩短 73.7% |
| 结构检查      | 6 分钟  | 8 分钟    | 增加 2 分钟  |
| 人工复核      | 14 分钟 | 22 分钟   | 增加 8 分钟  |
| 总耗时       | 83 分钟 | 48 分钟   | 缩短 42.2% |

人工方式与AI辅助方式耗时对比



从效率结果看，AI 辅助方式明显降低了初稿生成成本。虽然 AI 候选需要更多复核时间，但总耗时仍从 83 分钟下降到 48 分钟，节省比例为：


$$TimeSaving = \frac{83 - 48}{83} \times 100\% = 42.2\%$$

这说明 AI 的主要价值并不是取消人工复核，而是把人工工作从“从零编写”转变为“筛选、修订和确认”。对于规则数量持续增加的 SpecAlign 项目而言，这种工作方式更适合规模化测试设计。

5.2 覆盖能力对比

| 覆盖指标       | 人工方式  | AI 辅助方式 |
|------------|-------|---------|
| 候选测试用例数量   | 12    | 30      |
| 最终有效测试用例数量 | 9     | 24      |
| 覆盖策略类型数量   | 4     | 7       |
| 高风险策略覆盖率   | 66.7% | 100%    |
| 平均每类策略样本数  | 3.0   | 4.3     |

策略覆盖能力对比



覆盖结果表明，AI 辅助方式在策略多样性方面优势明显。人工方式容易优先覆盖直接请求、角色扮演等常见策略，而 AI 辅助方式能够补充情感操控、多轮递进和模糊利用等更复杂的场景。这些场景恰恰是 AI 安全测试中容易产生边界问题的部分，因此对 SpecAlign 的测试过程具有实际价值。

5.3 质量复核结果

| 质量指标    | 人工方式   | AI 辅助方式 | 说明              |
|---------|--------|---------|-----------------|
| 结构完整率   | 100.0% | 93.3%   | AI 有 2 条缺少复核要点  |
| 人工复核通过率 | 75.0%  | 80.0%   | AI 候选经筛选后保留比例略高 |
| 无关样本比例  | 8.3%   | 6.7%    | AI 有 2 条目标规则关联弱 |
| 模板化样本比例 | 0.0%   | 6.7%    | AI 生成存在模板化问题    |
| 最终有效样本数 | 9      | 24      | AI 有效样本数量更高     |


AI 辅助方式并非在所有质量指标上都更优。其结构完整率低于人工方式，说明 AI 输出仍需格式约束；模板化样本比例高于人工方式，说明 AI 在批量生成时存在表达重复问题。但是，AI 的人工复核通过率和最终有效样本数更高，说明在增加结构校验和人工筛选后，AI 候选能够提供更丰富的有效输入。

5.4 样本筛选矩阵

| 复核结论    | 人工方式 | AI 辅助方式 |
|---------|------|---------|
| 直接保留    | 6    | 16      |
| 小幅修改后保留 | 3    | 8       |
| 因关联弱删除  | 1    | 2       |

| 复核结论       | 人工方式 | AI 辅助方式 |
|------------|------|---------|
| 因表达模板化删除   | 0    | 2       |
| 因复核点不可操作删除 | 1    | 1       |
| 因风险意图过宽删除  | 1    | 1       |

AI候选样本处理结果



从样本筛选矩阵看，AI 生成结果不是简单的“可用”或“不可用”。其中一部分可以直接保留，一部分需要小幅修改，还有一部分必须删除。这说明过程设计中必须保留人工复核环节。如果取消人工复核，AI 辅助方式可能把模板化或关联较弱的样本引入测试集；如果保留人工复核，AI 能显著扩大候选空间，提高最终有效样本数量。

5.5 评分结果

为了更直观比较两种方式，本次验证采用综合评分模型：

$Score = 0.30E + 0.30C + 0.25Q + 0.15R$

其中，*E* 为效率得分，*C* 为覆盖得分，*Q* 为质量得分，*R* 为可复核性得分。各项得分采用 100 分制，综合结果如下：

| 维度              | 权重   | 人工方式 | AI 辅助方式 |
|-----------------|------|------|---------|
| 效率得分 <i>E</i>   | 0.30 | 58   | 86      |
| 覆盖得分 <i>C</i>   | 0.30 | 62   | 92      |
| 质量得分 <i>Q</i>   | 0.25 | 82   | 78      |
| 可复核性得分 <i>R</i> | 0.15 | 80   | 84      |

| 维度   | 权重   | 人工方式 | AI 辅助方式 |
|------|------|------|---------|
| 综合得分 | 1.00 | 69.0 | 85.0    |

综合评分显示，AI 辅助方式在效率和覆盖方面提升明显，质量方面略低于人工方式，但差距可以通过结构化提示词和质量门控制。总体而言，AI 辅助方式更适合作为 SpecAlign 构建过程中的候选生成机制，而不是完全替代人工测试分析。

## 6. 结果分析

本次验证表明，AI 技术在测试用例生成场景中的主要价值是扩大候选空间和提高初稿效率。人工方式的优势在于表达更稳定，错误类型较少，但由于人工编写时间较长，在规则数量增加时难以保持策略多样性。AI 辅助方式的优势在于生成速度快、策略覆盖广，并且能够同时输出复核要点，使测试用例更容易进入过程管理体系。

同时，AI 辅助方式也暴露出三个问题。第一，AI 候选存在模板化表达，尤其在批量生成同类策略时容易使用相似句式。第二，部分候选与目标规则关联不够紧密，需要人工判断是否真正触发目标风险。第三，如果提示词没有明确约束输出字段，AI 可能遗漏复核要点或生成过于笼统的风险描述。这些问题说明，AI 的引入必须配套提示词模板、结构化输出格式和人工复核机制。

## 7. 改进建议

根据验证结果，建议在 SpecAlign 的构建过程中正式增加“AI 候选生成”子活动。该活动应位于测试规格设计之后、正式对抗测试之前。AI 生成的候选样本不得直接进入测试种子库，必须先通过字段完整性校验，再经过测试分析师复核。对于被删除的样本，应记录删除原因，并将高频问题反馈给提示词模板。

建议将候选样本保留标准定义为：目标规则明确、策略类型明确、风险意图具体、提示文本具有真实用户语境、复核要点可操作。若样本只满足其中部分条件，应进入修改后复核队列；若目标规则关联弱或风险意图不可判断，则应直接删除。

## 8. 验证结论

本次原型验证说明，AI 辅助测试用例生成能够显著提升 SpecAlign 测试构建过程的效率和覆盖能力。在本次验证规模下，AI 辅助方式将总耗时从 83 分钟降低到 48 分钟，最终有效样本数从 9 条增加到 24 条，覆盖策略类型从 4 类增加到 7 类。虽然 AI 输出存在模板化和个别字段缺失问题，但通过结构校验和人工复核可以有效控制风险。

因此，本报告认为该场景具备较强落地价值。合理的过程定位不是“AI 替代测试分析师”，而是“AI 生成候选，人工确认质量，系统记录结果”。这种模式既利用了 AI 的生成效率，又保留了软件过程管理所要求的可追溯性和质量责任边界。