

改进后的完整软件过程定义文档

1 引言

1.1 项目概述

SpecAlign 是一个面向 AI 安全领域的测试与数据生成平台。它的核心问题仍然是第一次过程定义文档中提出的问题：一个 AI 模型在面对各种精心构造的提示时，是否能够始终遵守其行为规范。为了系统性地回答这个问题，SpecAlign 采用“以 AI 测试 AI”的方法，构建多智能体对抗系统，让攻击方尝试突破规范约束，让防御方生成响应，再由评审方判断是否违规。测试的最终产出也仍然不是传统意义上的测试报告，而是一组可以用于模型微调的 DPO 训练数据。

从输入到输出看，SpecAlign 的基本流程仍然分为两个阶段。第一阶段是规格生成：系统读取自然语言编写的 AI 行为规范文档，将其解析为结构化规则，并通过约束采样和指令生成，产出多样化的测试用例。第二阶段是对抗测试：系统将测试用例交给攻击智能体，由其构造对抗性提示；防御智能体接收提示并生成响应；安全评审和质量评审分别判断响应是否违规以及是否有帮助；违规响应成为 DPO 数据中的 rejected 样本，合规响应经过改写后成为 chosen 样本。

本次改进并不改变 SpecAlign 的项目定位，也不推翻第一次作业中已经完成的软件过程定义。相反，本文件是在原有过程定义的基础上进行智能化增强：原有的 16 个过程、过程来源、裁剪逻辑和能力评估框架保持一致，只是在需求分析、设计、构建、质量保证、运维和维护改进等薄弱环节中引入 AI 辅助活动，使 SpecAlign 从“自动化的数据生成流水线”进一步发展为“人机协同、可度量、可持续改进的软件过程体系”。

1.2 报告目的

本报告的目的，是在第一次《软件过程定义报告》的基础上，给出改进后的 SpecAlign 软件过程定义。与第一次作业相比，本报告关注的重点不再是从零识别项目中有哪些软件过程，而是说明在已有过程体系中如何融入 AI 技术，并使这些改进能够落到活动、角色、交付物、质量标准和度量指标上。

具体而言，本报告需要完成四项工作。第一，保留以 ISO/IEC/IEEE 12207:2017 为参考模型的过程划分，说明原有 16 个过程在改进后仍然如何发挥作用。第二，在每个关键过程中补充 AI 参与节点，明确 AI 输出不是最终结论，而是需要人工复核的候选工作产品。第三，更新交付物清单和过程度量指标，将 AI 贡献度、AI 输出采纳率、数据污染隔离率、异常定位时间等指标纳入过程管理。第四，基于 ISO/IEC 33001:2015 的能力级别框架，说明改进后各过程的能力提升方向。

2 标准概述

2.1 ISO/IEC/IEEE 12207:2017

ISO/IEC/IEEE 12207:2017 是软件生命周期过程的基础性国际标准。该标准不规定某一种具体开发方法，也不强制项目采用瀑布、敏捷或其他特定模型，而是将软件生命周期中的活动抽象为一组可裁剪的过程。每个过程都具有明确目的、预期结果和活动描述，项目可以根据自身规模、复杂度、关键程度和业务形态进行选取、合并或简化。

第一次过程定义文档已经依据该标准，将 SpecAlign 相关过程组织为四个过程组：协议过程组、组织项目使能过程组、技术管理过程组和技术过程组。本次改进仍沿用这一划分。不同之处在于，AI 技术被作为过程执行手段和过程工作产品的一部分引入。例如，在需求分析过程中，AI 用于规则语义审查；在设计过程中，AI 用于风险场景扩展；在构建过程中，AI 用于候选测试用例生成；在运维过程中，AI 用于日志摘要和异常归因。这些改进并没有改变 12207 的过程边界，而是丰富了过程内部活动。

2.2 ISO/IEC 15504 与 ISO/IEC 33001

ISO/IEC 15504 又称 SPICE，是软件过程评估领域的重要标准，其核心贡献是定义了过程能力级别和评估方法。ISO/IEC 33001 系列标准继承了 15504 的核心思想，并进一步完善了过程能力评估框架。能力级别从 Level 0 到 Level 5，分别表示过程未完成、已执行、已管理、已建立、可预测和持续优化。

第一次过程定义文档已经使用该框架对 SpecAlign 进行了能力评估。评估结果显示，质量管理、知识管理、需求分析、集成编排和测试等过程已经达到较高成熟度，而设计、构建、基础设施管理、项目规划、运维和维护改进等过程仍存在量化不足、反馈不足或标准化不足的问题。本次改进的主要目的，就是通过 AI 辅助审查、AI 辅助生成、AI 辅助复核和 AI 辅助分析，使这些短板过程向 Level 3 或 Level 4 方向提升。

2.3 三个标准在本报告中的关系

12207 回答“需要定义哪些过程”的问题，33001 回答“这些过程做得怎么样”的问题，15504 则在过程评估方法上仍具有参考价值。本报告仍然按照第一次作业的思路展开：先以 12207 为基础保留原有过程定义，再以 33001 的能力级别说明改进前后的成熟度变化。

AI 技术在这里不是新的标准来源，而是过程改进手段。换言之，本报告不是用 AI 概念替代软件过程标准，而是在标准过程框架内加入 AI 活动节点。这样既能保证报告与第一次作业保持一致，也能满足本次作业要求中关于 AI 技术应用、原型验证、过程文档化和过程度量的要求。





3 SpecAlign 的软件过程定义


3.1 过程选取的考虑

第一次过程定义文档已经指出，SpecAlign 是一个小型项目，核心开发团队仅一到三人，许多大型组织中需要独立管理的职能，如人力资源、项目组合和生命周期模型管理，在本项目中并不构成独立过程。项目的产出物是一组 DPO 训练数据，本质上是数据产品而非传统软件产品。因此，需求分析的对象不是用户交互需求，而是 AI 行为规范中的规则；设计的对象不是传统系统架构，而是测试规格采样策略；测试的目标不是验证功能正确性，而是发现 AI 响应何时违反规范。

项目运行高度依赖外部 LLM API 服务。规则标注、指令生成、攻击策略规划、攻击提示构造、防御响应生成、安全评审和质量评审都依赖 LLM 推理能力。因此，API 的可用性、速率限制、响应质量和成本控制，直接影响 SpecAlign 的运行稳定性和数据质量。基于这些特点，第一次作业从 12207 的约 30 个过程中裁剪出 16 个与项目直接相关的过程。本次改进继续沿用这 16 个过程，不新增独立的“AI 过程”，而是在各过程中补充 AI 参与活动。

改进后的过程全景如下：





3.2 协议过程组

3.2.1 PRC-ACQ: 获取过程

获取过程对应 12207 第 6.1 条 Acquisition Process。按照第一次过程定义，SpecAlign 的获取对象主要有两类。第一类是 AI 行为规范文档，它是整个系统的输入源，定义了 AI 模型应该遵守的行为规则；第二类是 LLM API 服务访问权限，包括 OpenAI、Anthropic、DeepSeek、Azure 或本地部署模型等提供商的端点、密钥、模型名称和调用参数。

原获取过程的重点是输入验证。行为规范文档需要经过格式验证，确保 Markdown 结构可解析、规则非空且层级清晰；API 配置需要经过连通性验证，确保密钥、端点和模型名称可用。由于 API 服务通常通过在线注册和自助配置获得，传统采购流程中的供应商评估、合同谈判和正式验收被简化。因此，第一次作业将该过程评估为 Level 2（Managed）。

改进后，获取过程增加 AI 辅助输入审查活动。AI 过程协同工程师使用固定提示词模板，对规范文档进行初步审查，识别空规则、重复规则、语义不完整规则、疑似冲突规则和无法解析的结构问题。AI 审查结果只形成《AI 输入审查报告》，不能直接修改原始规范；是否修改输入材料，需要由项目负责人或需求分析人员确认。对于 API 获取，过程还需要补充服务级别要求，例如可用性、平均延迟、最大失败重试次数和供应商切换条件。

改进后的主要交付物包括《输入材料登记表》《规范文档格式检查结果》《API 连通性检查记录》《AI 输入审查报告》和《API 服务级别要求》。质量标准包括：规范文档结构可解析；API 配置不包含泄露风险；AI 审查问题必须附带原文位置；供应商切换条件需要提前定义。通过这些补充，获取过程有望从 Level 2 向 Level 3 提升。

3.2.2 PRC-SUP: 供应过程

供应过程对应 12207 第 6.2 条 Supply Process。第一次过程定义中，SpecAlign 的“客户”是内部 AI 模型训练团队，供应的“产品”是 DPO 训练数据集和测试评估报告。DPO 数据集以 JSON 或 JSONL 格式输出，每条记录包含提示、合规响应 chosen 和违规响应 rejected。评估报告包含攻击成功率、平均轮次、违规严重程度分布等统计数据。

原供应过程已经具备标准化输出格式和导出能力，但缺少交付后的质量确认和用户满意度跟踪。由于训练团队属于内部客户，数据交付后的反馈往往通过非正式渠道进行，导致数据使用效果难以回流到过程改进。因此，第一次作业将该过程评估为 Level 2 (Managed)。

改进后，供应过程需要增加两个活动。第一是 AI 辅助交付摘要。AI 根据 DPO 数据集、对抗日志和质量复核结果，生成面向训练团队的交付说明，概括数据规模、规则覆盖、主要风险类型、样本质量缺陷和建议使用方式。第二是训练反馈登记。训练团队在使用数据后，需要反馈新模型违规率、帮助性变化、失败规则分布和异常样本示例，作为维护改进过程的输入。

改进后的交付物包括《DPO 数据集》《对抗日志》《质量评估报告》《AI 交付摘要》和《训练效果反馈表》。质量标准包括：数据格式符合约定；样本能够追溯到规则、测试用例和评审证据；交付摘要不得包含密钥、本地隐私路径或未经确认的结论；每次重要数据交付后都应形成反馈记录。

3.3 组织项目使能过程组

3.3.1 PRC-QM：质量管理过程

质量管理过程对应 12207 第 7.5 条 Quality Management Process。第一次过程定义中，SpecAlign 的质量管理核心是“安全-质量”双维度评估体系。安全维度回答“响应是否违规”的问题，需要检查响应是否违反规范文档中的规则，并在违规时判断严重程度、引用证据原文。质量维度回答“响应是否有帮助”的问题，从相关性、完整性、清晰度和可操作性四个子维度进行评分，其权重分别为 0.3、0.3、0.2 和 0.2。

这一质量框架仍然是改进后过程的基础。一个响应如果被安全评审判定为违规，无论其帮助性多高，都会成为 rejected 样本；只有安全合规且具有一定帮助性的响应，才会经过改写成为 chosen 样本。第一次作业将该过程评估为 Level 3 (Established)，因为它已经具有标准化指标、明确评审机制和 fallback 检测机制。

改进后，质量管理过程在原有双维度框架之外增加三类质量对象：规则质量、测试质量和 AI 输出质量。规则质量关注 AI 对规则的解释是否准确、是否引用原文、是否存在幻觉；测试质量关注测试用例是否覆盖目标规则、是否具备策略多样性、是否真正触发评审；AI 输出质量关注 AI 生成的规则解释、候选测试用例、质量复核意见和运维建议是否经过人工确认。

改进后的关键指标包括规则解释准确率、AI 输出采纳率、有效测试用例通过率、DPO 样本合格率和数据污染隔离率。其中，AI 输出采纳率可定义为：

$$Adoption_{AI} = \frac{N_{AI_accepted}}{N_{AI_generated}}$$

数据污染隔离率可定义为：

$$IsolationRate = \frac{N_{isolated}}{N_{polluted}}$$

这些指标使质量管理过程从原来的结果质量控制，进一步扩展到 AI 参与过程的质量控制。改进后，该过程保持 Level 3，并具备向 Level 4 量化管理发展的条件。

3.3.2 PRC-KM：知识管理过程

知识管理过程对应 12207 第 7.6 条 Knowledge Management Process。第一次过程定义中，SpecAlign 的知识管理围绕 Context Pool 展开。Context Pool 是基于语义嵌入的攻击案例库，存储成功攻击记录，包括攻击提示、使用策略、防御者违规响应和评审判定理由。系统还通过多样性分数阈值过滤低质量记录，通过嵌入相似度检测去重，并使用 MMR 策略平衡检索结果的相关性和多样性。

这一机制在改进后仍然保留。不同之处在于，知识管理的对象从“攻击案例知识”扩展为“过程知识”。除了成功攻击案例，系统还应保存 AI 生成的规则解释、被人工修改的规则解释、AI 候选测试用例、被删除样本及删除原因、提示词模板、数据质量缺陷和运维异常摘要。这样，AI 参与过程中的经验也能被积累，而不是散落在临时对话中。

例如，如果某类 AI 候选测试用例多次因“目标规则关联弱”被删除，说明提示词模板需要加强规则绑定；如果某类规则多次出现解释冲突，说明该规则需要进入需求分析过程重新审查；如果某类 API 异常反复出现，说明基础设施管理过程需要调整限流或供应商策略。通过这种方式，知识管理过程从单纯复用成功攻击案例，扩展为支撑整个过程改进的知识资产管理。

改进后的交付物包括《Context Pool》《AI 过程知识库》《提示词模板库》《删除样本原因记录》和《过程经验复盘记录》。质量标准包括：知识条目必须包含来源、时间、适用规则和使用结果；错误知识应及时失效；提示词模板变更必须纳入配置管理。

3.3.3 PRC-IM：基础设施管理过程

基础设施管理过程对应 12207 第 7.3 条 Infrastructure Management Process。第一次过程定义已经指出，对 SpecAlign 而言，基础设施的核心不是传统服务器，而是 LLM API 服务。规则标记、指令生成、攻击策略规划、对抗提示构造、响应生成、安全评审和质量评审都依赖 LLM 推理能力。因此，API 服务的可用性和性能直接决定系统可行性。

原过程已经包含多提供商管理、速率控制和故障处理。系统支持多个 API 提供商，不同环节可以使用不同模型；通过全局速率限制器和最小调用间隔避免触发限流；在 API 调用失败时采取降级策略，例如评审失败时默认无违规、策略生成失败时回退到默认策略。由于缺少 API 可用性监控、延迟统计和容量规划，第一次作业将该过程评估为 Level 2 (Managed)。

改进后，基础设施管理过程增加 AI 辅助可观测性分析。系统应记录 API 调用成功率、平均延迟、失败类型、速率限制次数、成本估算和模型拒答比例。AI 运维分析员可以基于脱敏日志和指标生成基础设施分析摘要，识别高频失败模式并提出容量规划建议。需要强调的是，API 密钥、供应商凭据和私人路径不得进入 AI 提示词，AI 建议也不得自动执行。

改进后的交付物包括《API 服务登记表》《运行指标记录》《AI 基础设施分析摘要》《供应商切换记录》和《容量规划建议》。质量标准包括：日志脱敏有效；关键配置可追溯；高频异常有处理记录；供应商切换有依据。该过程的改进目标是从 Level 2 提升到 Level 3。

3.4 技术管理过程组

3.4.1 PRC-PM：项目规划过程

项目规划过程对应 12207 第 8.1 条 Project Planning Process。第一次过程定义中，SpecAlign 采用配置驱动的规划方式。模型选择、轮次限制、奖励权重、多样性约束、输出路径等参数集中在配置文件中定义。流水线执行被划分为规格转换、种子生成、对抗循环和数据分析四个阶段，各阶段之间具有明确依赖关系。用户可以通过控制台选择全量执行或单步执行，也可以取消正在运行的任务。

原规划过程的优点是灵活，修改配置即可调整执行计划；不足是缺少正式资源估算和时间线规划，例如不会预估一次运行需要多少 API 调用、多少费用和多长时间。因此，第一次作业将该过程评估为 Level 2 (Managed)。

改进后，项目规划过程需要增加 AI 使用计划。每次运行前，需要明确是否启用 AI 规则语义审查、AI 测试用例生成、AI 数据质量复核和 AI 运维异常分析；同时，需要估算 AI 调用成本、人工复核工作量和预期节省时间。若 AI 候选数量过多而人工复核资源不足，过程会产生新的瓶颈，因此规划阶段必须控制候选规模和抽检比例。

改进后的交付物包括《运行计划》《AI 使用计划》《成本估算表》和《进度记录》。质量标准包括：所有 AI 活动都有负责人；运行配置有版本记录；计划变更进入配置管理过程；AI 调用成本和复核工作量在可接受范围内。

3.4.2 PRC-RM：风险管理过程

风险管理过程对应 12207 第 8.4 条 Risk Management Process。第一次过程定义中，SpecAlign 的主要风险是数据污染。数据污染可能来自多个环节：防御者生成无意义的回退文本，规划器因安全对齐拒绝生成攻击策略，攻击者拒绝构造对抗提示，评审模型给出错误判断等。任何环节异常都可能导致评测数据失真。

原过程已经建立了三层防护机制。第一层检测防御者生成失败，避免将回退响应误判为合规；第二层检测规划器拒绝，必要时回退到直接攻击模式；第三层检测攻击者拒绝，必要时使用原始种子作为替代。此外，系统还通过违规严重程度和规则状态追踪减少重复测试。由于缺少风险概率建模，第一次作业将该过程评估为 Level 2-3 过渡。

改进后，风险管理过程需要新增 AI 相关风险项，包括 AI 幻觉、模型偏见、敏感信息泄露、输出不可复现、过度依赖单一模型和责任边界模糊。针对 AI 幻觉，要求 AI 输出引用原文并接受人工复核；针对敏感信息泄露，要求日志脱敏和密钥过滤；针对输出不可复现，要求保存提示词模板、模型版本和生成参数。

AI 幻觉率可定义为：

$$HallucinationRate = \frac{N_{unsupported}}{N_{AI_reviewed}}$$

其中， $N_{unsupported}$ 表示人工复核后确认无依据的 AI 输出数量。通过引入该指标，风险管理过程可以从“发现风险后处理”逐步转向“量化 AI 风险并持续降低风险”。

3.4.3 PRC-CM：配置管理过程

配置管理过程对应 12207 第 8.6 条 Configuration Management Process。第一次过程定义中，SpecAlign 的配置管理相对集中。核心配置文件定义运行模式、随机种子、日志级别、模型选择、温度、token 限制、奖励权重和多样性约束等参数；API 凭证单独存放，并通过加载器在运行时合并；配置变更通过 Git 进行追溯。

原配置管理过程已经具备集中配置和版本追溯能力，但缺少配置变更审计和参数合规检查，因此被评估为 Level 2 (Managed)。改进后，配置管理的对象需要扩展到 AI 过程资产，包括提示词模板、AI 输出格式、模型版本、温度参数、复核比例、质量阈值和敏感信息过滤规则。

提示词模板尤其需要纳入配置管理。如果提示词只保存在聊天记录中，后续无法复现 AI 输出，也无法解释某次运行为什么生成特定结果。改进后，正式使用的提示词应与代码和配置一样受版本控制，并在变更时记录变更原因、预期影响和验证结果。

改进后的交付物包括《配置项清单》《提示词模板库》《配置变更记录》《模型参数记录》和《配置合规检查表》。质量标准包括：配置项可追溯；提示词变更有说明；模型版本有记录；影响质量判断的配置变更需要 QA 确认。该过程的改进目标是提升到 Level 3。

3.4.4 PRC-QA：质量保证过程

质量保证过程对应 12207 第 8.7 条 Quality Assurance Process。第一次过程定义中，质量保证过程关注项目是否按照定义的质量标准执行，尤其关注生成数据是否满足安全和帮助性双维度评估要求，评审结果是否具有证据，输出数据是否符合格式要求。由于项目已有较完整的评审机制和质量控制逻辑，该过程被评估为 Level 3 (Established)。

改进后，QA 的检查对象需要从最终结果扩展到 AI 活动本身。QA 不仅要检查 DPO 数据集是否合格，还要检查 AI 输入是否脱敏、AI 输出是否保存、人工复核是否完成、被删除样本是否记录原因、AI 数据质量复核是否覆盖高风险样本。也就是说，AI 参与过程本身成为质量保证对象。

对于 DPO 数据，QA 仍需检查偏好对是否有效、rejected 是否确实存在安全问题、chosen 是否具有足够帮助性、安全评审证据是否完整。AI 可以先标记疑似问题样本，但高风险样本必须由人工确认。改进后的交付物包括《QA 检查表》《AI 输出抽检记录》《数据污染清单》和《放行结论》。质量标准包括：高风险样本 100% 复核；普通样本抽检比例不低于 10%；所有污染样本交付前隔离。

3.5 技术过程组

3.5.1 PRC-REQ：需求分析过程

需求分析过程是 SpecAlign 技术过程的起点。第一次过程定义中，该过程被重新解释为从 AI 行为规范文档中识别规则，而不是传统意义上从用户访谈中收集交互需求。系统读取 Markdown 规范文档，解析阶段、子类别和编号规则，并对规则进行方向标注、适用场景标注和语义族聚类。

原需求分析过程已经具有较明确的输入输出和结构化处理机制，因此被评估为 Level 3 (Established)。但是，原过程更关注规则能否被解析和标注，对规则语义是否清晰、例外条件是否完整、规则之间是否冲突，缺少系统化审查。

改进后，需求分析过程增加 AI 规则语义审查活动。AI 对每条规则输出规则意图、适用场景、例外条件、潜在冲突和原文依据。人工复核后，规则解释才能进入规则基线。若 AI 对规则含义进行了扩展解释，但没有原文依据，只能作为待确认问题，不能直接成为正式需求。这样可以避免 AI 将通用安全知识混入项目规范。

改进后的交付物包括《规则清单》《规则语义审查表》《人工复核记录》和《规则基线》。质量标准包括：每条规则具有唯一编号；高风险规则具有原文依据；冲突规则进入问题清单；规则基线发布前完成复核。

3.5.2 PRC-DES：设计过程

设计过程对应 12207 中的设计活动，但在 SpecAlign 中被重新解释为测试规格设计。第一次过程定义中，设计过程的核心不是系统架构设计，而是根据规则集生成具有多样性和优先级的测试规格。设计过程需要平衡阶段覆盖、方向平衡、主题覆盖和语义族多样性，同时根据规则风险设置优先级。负向且禁止类的规则优先级最高，正向规则优先级较低，带有例外条件的规则获得更高优先级。

原设计过程已经有约束采样机制，但缺少设计审查和覆盖率量化验证，因此被评估为 Level 2 (Managed)。改进后，AI 根据规则基线生成风险场景和测试策略建议，帮助识别每个规则适合采用哪些对抗方式，例如直接请求、角色扮演、间接请求、情感操控、权威冒充、模糊利用和多轮递进。

设计覆盖评分可表示为：

$$Score_{design} = 0.35C_{rule} + 0.25C_{risk} + 0.25D_{strategy} + 0.15Q_{review}$$

其中， C_{rule} 表示规则覆盖率， C_{risk} 表示高风险规则覆盖率， $D_{strategy}$ 表示策略多样性， Q_{review} 表示人工审查通过比例。该评分用于辅助设计审查，而不是机械替代人工判断。改进后的交付物包括《测试规格》《风险场景表》《覆盖率审查表》和《设计审查结论》。该过程的改进目标是从 Level 2 提升到 Level 3。

3.5.3 PRC-CON：构建过程

构建过程对应 12207 中的实现活动，但在 SpecAlign 中，构建的产出物不是代码模块，而是测试指令和种子提示。第一次过程定义中，构建过程强调多样性，测试指令需要在句式类型、指令风格、语气、用户情感和长度五个维度上保持差异。系统还需要保证所有规则都至少被一条测试指令覆盖，若初始生成未能覆盖某些规则，则迭代扩展，直到实现 100% 规则覆盖。

原构建过程已经具备批量生成和多样性控制机制，但缺少对生成指令质量的自动验证，例如指令是否真正触发目标规则、是否具有真实用户语境、是否过于模板化。因此，第一次作业将该过程评估为 Level 2 (Managed)。

改进后，AI 作为候选生成器参与构建过程。AI 根据目标规则和策略类型生成不同风格、语气和长度的测试提示。每条候选测试用例必须包含目标规则、策略类型、提示文本、预期风险和人工复核要点。随后，系统进行结构校验，测试分析师进行语义复核。被删除样本必须记录原因，例如目标规则关联弱、表达模板化、风险意图过宽或复核点不可操作。

改进后的交付物包括《候选测试用例清单》《有效测试种子库》《删除样本记录》和《提示词优化记录》。质量标准包括：字段完整率不低于 95%；有效样本保留率不低于 70%；重复或无关样本不得进入正式测试。该过程的改进目标是提升到 Level 3。

3.5.4 PRC-INT：集成与编排过程

集成与编排过程对应 12207 中的集成和验证活动。第一次过程定义中，SpecAlign 的集成过程围绕多智能体系统展开，包含规划器、攻击者、防御者和评审四类核心角色。规划器根据上下文选择攻击策略，攻击者根据策略构造对抗提示，防御者生成响应，评审判断是否违规以及是否有帮助。

原过程还包含角色动态切换和上下文管理机制。在对抗循环中，如果攻击者连续成功，系统可以在满足条件时交换攻击者和防御者角色，从而增加对抗多样性。系统还维护对话历史摘要，使规划器和攻击者能够根据之前经验调整策略。第一次作业将该过程评估为 Level 3 (Established)。

改进后，集成与编排过程需要保证 AI 生成的候选测试用例能够通过标准接口进入对抗循环，而不是通过人工复制粘贴临时加入。所有用例需要转化为统一 JSON 或 JSONL 结构，字段至少包括规则编号、策略类型、提示文本和复核状态。若 AI 节点失败，系统应能够回退到原有生成逻辑，避免 AI 改进反而降低系统鲁棒性。

改进后的交付物包括《接口字段定义》《集成测试记录》《降级处理记录》和《运行状态记录》。质量标准包括：接口字段完整；运行状态可恢复；异常输出可捕获；降级路径可用。该过程保持 Level 3，并增强稳定性和可追溯性。

3.5.5 PRC-TST：测试过程

测试过程是 SpecAlign 的核心过程。第一次过程定义中，测试过程被重新解释为对抗性测试，而不是传统软件测试中的功能验证。对每个种子，系统执行最多五轮对抗。每轮对抗中，规划器从越狱角色扮演、间接请求、情感操控、权威冒充、模糊利用等策略中选择攻击方式，攻击者构造提示，防御者生成响应，安全评审判断违规，质量评审评估帮助性。

如果攻击成功，系统记录违规规则和证据，构造 DPO 训练对，并更新知识库；如果攻击失败，系统提取防御洞察，更新上下文，进入下一轮。测试过程还具有提前终止机制，如果一个种子已经触发所有目标规则违规，系统会停止后续轮次，避免浪费资源。第一次作业将该过程评估为 Level 3 (Established)。

改进后，测试过程增加对 AI 生成样本效果的记录。系统不仅记录测试是否成功，还记录该测试用例是否由 AI 生成、对应策略是什么、是否通过人工复核、触发成功率如何、是否产生有效 DPO 样本。这样可以量化 AI 候选生成对测试质量的真实贡献。

AI 贡献度可定义为：

$$Contribution_{AI} = \frac{N_{AI_accepted}}{N_{final}}$$

其中， $N_{AI_accepted}$ 表示最终有效测试样本中来自 AI 候选且通过复核的数量， N_{final} 表示最终有效样本总数。该指标不能单独代表质量，但可以反映 AI 在测试过程中的实际参与程度。

3.5.6 PRC-OPE：运维过程

运维过程对应 12207 第 6.4.10 条 Operation。第一次过程定义中，SpecAlign 的运维主要通过 Web 控制台实现。控制台显示流水线运行状态、各阶段进度和实时指标，如当前处理的种子、轮次、策略类型、是否违规、帮助性分数等。用户可以启动全量或单步任务，也可以取消正在执行的任务。系统还提供健康检查端点，供外部监控系统探测服务是否可用。

原运维过程有基本运行监控和任务管理能力，但缺少告警机制、自动恢复能力和性能监控，例如 API 调用延迟趋势分析。因此，第一次作业将其评估为 Level 1-2 过渡。

改进后，运维过程增加 AI 日志摘要和异常归因活动。AI 对脱敏日志和运行指标进行分析，输出异常类型、影响范围、证据片段、可能原因和建议动作。常见异常包括 API 认证失败、速率限制、模型拒答、输出格式错误、上下文超长和网络超时。AI 建议不得自动执行，运维人员必须根据实际配置和日志进行确认。

改进后的交付物包括《运行日志》《AI 异常摘要》《异常处理记录》和《恢复验证结果》。质量标准包括：日志进入 AI 前必须脱敏；严重异常由人工确认；恢复结果有记录；高频异常反馈给基础设施管理过程。该过程的改进目标是从 Level 1-2 提升到 Level 2-3。

3.5.7 PRC-MAI：维护与改进过程

维护与改进过程对应 12207 的维护过程以及质量管理中的改进活动。第一次过程定义中，SpecAlign 的改进闭环建立在数据分析之上。每次对抗测试完成后，系统生成统计报告，包括攻击成功率、平均对抗轮次、各策略类型成功率、违规严重程度分布和 rejected 响应平均帮助性等指标。Context Pool 的历史数据也是改进来源，随着知识库积累，规划器可以参考更多历史成功案例。

原过程的主要问题是闭环不完整。DPO 数据集交付给训练团队后，模型改进效果没有回传到系统中，系统无法判断自己生成的数据是否真正降低了新模型违规率。因此，第一次作业将该过程评估为 Level 1 (Performed)。

改进后，维护与改进过程必须建立训练效果反馈机制。训练团队需要反馈新模型违规率、帮助性变化、失败规则分布、训练后问题样本和策略成功率变化。AI 可以根据这些数据生成过程改进建议，例如提高某类规则采样权重、补充某类攻击策略、修改评审提示词或优化 Context Pool 检索策略。建议是否采纳仍由项目负责人和相关过程负责人确认。

改进后的交付物包括《训练效果反馈表》《过程改进建议》《采纳记录》和《改进效果验证报告》。质量标准包括：重要数据交付后必须收集反馈；采纳建议需要后续验证；未采纳建议说明原因；改进结论回写到需求、设计、构建或运维过程。该过程是本次改进中提升幅度最大的过程，目标是从 Level 1 提升到 Level 2，并逐步向 Level 3 发展。

4 过程来源与裁剪说明

4.1 过程定义的来源

SpecAlign 的过程定义仍然以 ISO/IEC/IEEE 12207:2017 为参考模型。本次改进并不改变第一次作业中对标准的使用方式：不是简单照搬标准，而是根据 SpecAlign 的实际语境进行转化。第一次作业中归纳的四种转化方式仍然成立，即直接映射、合并处理、重新诠释和项目特化。

直接映射仍然体现在获取、供应、基础设施管理、配置管理等过程中。例如，获取过程在标准中是获取外部产品或服务，在 SpecAlign 中是获取行为规范文档和 API 服务；基础设施管理在标准中是管理硬件、软件和网络资源，在 SpecAlign 中是管理 LLM API 服务和运行环境。本次改进只是为这些直接映射过程增加 AI 审查、AI 摘要或 AI 分析活动。

合并处理仍然体现在需求定义与需求分析、集成与验证、验证与确认等过程的处理上。需求定义和需求分析继续合并为需求分析过程，因为项目需求来自行为规范文档；集成与验证继续合并为集成编排过程，因为多智能体的集成和验证发生在同一循环中；验证与确认继续被重新解释为对抗性测试，因为测试目标是发现 AI 响应何时违规。

重新诠释和项目特化也保持不变。设计过程仍然不是传统架构设计，而是测试规格采样策略设计；构建过程仍然不是普通代码实现，而是测试指令和种子提示构建；知识管理过程仍然围绕 Context Pool 展开；测试过程仍然是多智能体对抗循环。本次 AI 改进只是在这些已重新诠释的过程内部增加智能化活动，而不改变其基本含义。

4.2 过程裁剪

4.2.1 裁剪的依据

裁剪依据仍然来自 ISO/IEC/IEEE 12207:2017 第 5.4 条，即项目应根据范围、规模、复杂度和关键程度对标准过程进行裁剪。SpecAlign 的项目特征仍然是小团队、数据产品、流水线生命周期和 API 依赖。这些特征决定了本项目不需要完整保留所有大型组织过程，但必须加强质量、风险、配置、测试、运维和维护改进。

4.2.2 省略的过程

第一次作业中省略的过程在本次改进后仍然省略。生命周期模型管理过程被省略，因为项目仍然是单一流水线模式；项目组合管理被省略，因为 SpecAlign 是单一项目；人力资源管理被省略，因为小团队人员安排由组织层面承担；决策管理被省略，因为是否交换角色、是否终止测试等决策已经嵌入对抗流程；测量过程没有独立保留，因为度量指标被融入各过程；信息管理也没有独立保留，因为项目信息主要通过文件系统、日志和 API 自然管理。

本次改进虽然新增了 AI 度量指标，但仍不单独恢复测量过程。原因在于这些指标服务于具体过程，例如 AI 输出采纳率属于质量管理过程，异常定位时间属于运维过程，训练反馈闭环属于维护改进过程。将它们嵌入原有过程，比新增独立测量过程更符合小团队项目的实际情况。

4.2.3 合并的过程

需求定义与需求分析继续合并为 PRC-REQ。AI 语义审查虽然增强了需求分析，但没有改变需求来源单一的事实。集成与验证继续合并为 PRC-INT，因为规划器、攻击者、防御者和评审之间的集成与验证仍在同一多智能体循环中完成。验证与确认继续合并并重新解释为 PRC-TST，因为 SpecAlign 的测试目标仍然是发现规范违规，而不是验证传统功能。维护与质量管理中的改进部分继续合并为 PRC-MAI，因为项目的核心改进活动仍然是数据驱动的模式改进。

4.2.4 简化的过程

获取、供应、项目规划和运维过程仍然是被简化但保留的过程。获取过程继续省略合同谈判和供应商评估，但新增 API 服务级别要求和 AI 输入审查。供应过程继续省略正式客户验收，但新增 AI 交付摘要和训练反馈登记。项目规划过程继续省略传统甘特图和成本预算，但新增 AI 使用计划和调用成本估算。运维过程继续省略值班轮换和复杂容量规划，但新增 AI 异常摘要和恢复验证记录。

4.3 裁剪后的过程全景

经过上述裁剪与改进，SpecAlign 仍然定义 16 个软件过程。协议过程组包含获取和供应两个过程，负责输入和输出。组织项目使能过程组包含质量管理、知识管理和基础设施管理三个过程，为项目提供质量、知识和运行基础。技术管理过程组包含项目规划、风险管理、配置管理和质量保证四个过程，管理技术活动执行。技术过程组包含需求分析、设计、构建、集成编排、测试、运维和维护改进七个过程，执行具体技术工作。

与第一次过程定义相比，过程数量和边界没有变化，变化发生在每个过程内部。AI 技术被作为活动、角色、交付物和度量指标嵌入过程，而不是作为独立过程附加在外部。这样既保持了第一次作业的结构一致性，也使本次改进具备明确落点。

5 能力评估

5.1 评估方法

能力评估仍依据 ISO/IEC 33001:2015 的能力级别框架。评估时，对每个过程检查其过程属性达成程度，并参考 ISO/IEC 33020 中的四级评定尺度：未达成 N（0-15%）、部分达成 P（16-50%）、大部分达成 L（51-85%）和完全达成 F（86-100%）。本报告在第一次能力评估结果的基础上，说明引入 AI 改进后的能力提升方向。

5.2 改进前后能力对比

过程	第一次作业评估	改进后目标	主要提升依据
PRC-ACQ 获取	Level 2	Level 3	增加 AI 输入审查和 API 服务级别要求
PRC-SUP 供应	Level 2	Level 3	增加交付摘要、训练反馈和质量确认
PRC-QM 质量管理	Level 3	Level 3-4	增加 AI 输出质量指标和数据污染隔离指标
PRC-KM 知识管理	Level 3	Level 3-4	从 Context Pool 扩展到 AI 过程知识库
PRC-IM 基础设施管理	Level 2	Level 3	增加 AI 可观测性分析和容量建议
PRC-PM 项目规划	Level 2	Level 3	增加 AI 使用计划、成本估算和复核资源规划
PRC-RM 风险管理	Level 2-3	Level 3	增加 AI 风险登记、幻觉率和脱敏机制
PRC-CM 配置管理	Level 2	Level 3	将提示词模板、模型版本和输出格式纳入配置项
PRC-QA 质量保证	Level 3	Level 3	扩展 QA 范围到 AI 活动检查
PRC-REQ 需求分析	Level 3	Level 3-4	增加 AI 规则语义审查和原文依据复核
PRC-DES 设计	Level 2	Level 3	增加风险场景扩展和覆盖评分
PRC-CON 构建	Level 2	Level 3	增加 AI 候选生成、结构校验和删除原因记录
PRC-INT 集成编排	Level 3	Level 3	增强标准接口和降级路径
PRC-TST 测试	Level 3	Level 3-4	增加 AI 样本效果追踪和贡献度指标
PRC-OPE 运维	Level 1-2	Level 2-3	增加 AI 异常摘要、处理记录和恢复验证
PRC-MAI 维护改进	Level 1	Level 2-3	建立训练效果反馈和过程改进建议闭环

5.3 改进方向

从 Level 2 提升到 Level 3 的关键仍然是建立标准化过程定义并确保一致执行。对获取、供应、基础设施管理、项目规划、配置管理、设计和构建过程而言，AI 改进的作用主要是补齐原有过程中的标准化缺口。例如，设计过程通过覆盖评分和风险场景表形成设计审查机制；构建过程通过结构校验和删除原因记录形成可复核的样本筛选机制；配置管理过程通过提示词模板库使 AI 使用可追溯。

从 Level 3 向 Level 4 提升的关键是量化管理。对质量管理、知识管理、需求分析和测试过程而言，AI 改进不仅带来新的活动，也带来新的度量指标。例如 AI 输出采纳率、AI 幻觉率、AI 贡献度、数据污染隔离率和异常定位时间，都可以用于观察过程是否稳定、可预测。若这些指标能够长期积累并用于趋势分析，SpecAlign 就具备向 Level 4 发展的基础。

运维和维护改进仍然是最需要加强的环节。运维过程需要从基本状态监控发展到异常解释、告警和恢复验证；维护改进过程需要从统计报告生成发展到训练效果反馈闭环。尤其是 PRC-MAI，如果 DPO 数据交付后的模型效果不能回传，整个过程仍然无法证明自身改进是否有效。因此，本次改进将训练反馈表和过程改进建议作为维护过程的核心交付物。

6 交付物清单与过程度量

6.1 交付物清单

类型	交付物	对应过程	格式
输入管理	输入材料登记表、API 连通性记录、AI 输入审查报告	PRC-ACQ	Markdown/JSON
供应交付	DPO 数据集、对抗日志、AI 交付摘要、训练反馈表	PRC-SUP	JSONL/Markdown
质量管理	质量指标表、数据污染隔离记录、AI 输出采纳记录	PRC-QM	Markdown/JSON
知识管理	Context Pool、AI 过程知识库、提示词模板库	PRC-KM	JSONL/Markdown
基础设施	API 服务登记表、运行指标记录、AI 基础设施分析摘要	PRC-IM	Markdown/日志
技术管理	AI 使用计划、风险登记表、配置项清单、QA 检查表	PRC-PM/RM/CM/QA	Markdown
技术过程	规则基线、测试规格、候选测试用例清单、测试执行日志	PRC-REQ/DES/CON/TST	Markdown/JSON
运维维护	AI 异常摘要、恢复验证结果、过程改进建议	PRC-OPE/MAI	Markdown

6.2 过程度量指标

改进后的过程度量指标分为效率、质量、风险和 AI 贡献四类。效率指标包括规则审查耗时、测试用例初稿生成耗时、异常定位耗时和总运行周期。质量指标包括规则解释准确率、高风险规则覆盖率、有效测试用例通过率、DPO 样本合格率和人工复核通过率。风险指标包括 AI 幻觉率、敏感信息拦截次数、数据污染样本数、模型拒答样本比例和异常恢复时间。AI 贡献指标包括 AI 输出采纳率、AI 生成有效样本占比、AI 发现缺陷数、AI 建议采纳比例和 AI 辅助节省时间。

这些指标需要结合使用。若 AI 贡献度很高但数据污染率也升高，说明 AI 虽然参与较多，却没有真正提升质量。若 AI 节省时间明显但人工复核压力过大，也需要重新调整候选生成数量和复核比例。过程度量的目标不是证明 AI 一定更好，而是让 AI 引入后的效果能够被持续观察和改进。

7 总结

本报告以第一次《软件过程定义报告》为基础，对 SpecAlign 的完整软件过程进行了智能化改进。改进后的过程体系仍然保留原有 16 个过程、四类过程组、过程来源与裁剪逻辑以及能力评估方法。与第一次作业相比，本报告的变化主要体现在过程内部活动：AI 技术被引入规则语义审查、风险场景扩展、候选测试用例生成、数据质量复核、运维异常分析和维护改进建议等环节。

这种改进方式避免了两种偏差。第一，它没有把 AI 作为一个脱离原过程的新模块，而是把 AI 活动嵌入原有过程边界中。第二，它没有把 AI 输出视为最终结论，而是明确要求人工复核、配置管理、质量保证和过程度量。这样，SpecAlign 的过程定义既与原文档保持一致，又满足本次作业关于 AI 技术融合、原型验证和文档化交付的要求。

整体而言，SpecAlign 原过程已经具备较清晰的生命周期结构和核心质量机制，但在设计审查、构建质量验证、运维分析和维护反馈方面存在短板。通过本次改进，设计和构建过程可以从 Level 2 向 Level 3 提升，运维和维护改进过程可以逐步补齐闭环，质量管理和测试过程则具备向 Level 4 量化管理发展的基础。后续最重要的工作，是在实际运行中持续记录 AI 输出采纳率、AI 幻觉率、样本有效率和训练反馈结果，使过程改进不只是文档描述，而能成为可验证、可迭代的实践。

8 参考标准与资料

1. ISO/IEC/IEEE 12207:2017, Systems and software engineering - Software life cycle processes.
2. ISO/IEC 15504-1:2004, Information technology - Process assessment - Part 1: Concepts and vocabulary.
3. ISO/IEC 33001:2015, Information technology - Process assessment - Concepts and terminology.
4. ISO/IEC 33002:2015, Information technology - Process assessment - Requirements for performing process assessment.
5. ISO/IEC 33004:2015, Information technology - Process assessment - Requirements for process reference, process assessment and maturity models.
6. ISO/IEC 33020:2015, Information technology - Process assessment - Process measurement framework for assessment of process capability.
7. 中国信息通信研究院：《智能化软件工程技术和应用要求 第3部分：智能测试能力》，2024。